

FAQ's SEO On Page (Robots.txt y Sitemaps)

Robots.txt

¿El Robots.txt es para decirle a Google que no rastree una URL de mi web? ¿Cómo elijo esa url, la añado a robots.txt?

Tienes que indicarle por carpetas enteras o urls. Negarle el acceso al google bot.

¿Si tengo webs pequeñas (entre 30 y 50 Urls) es conveniente subir el archivo?

Sí, pero puedes dejarlo como está y añade, por ejemplo, el sitemap.

¿WP lo hace de manera automática?.

Sí y se genera automáticamente pero puedes personalizarlo.

¿Para el ejercicio de robots.txt lo que se pide es que ponga que url o texto tendría que subir a mi head, para que sólo google ads (desktop y mobile) y google imágenes accedan a página?

Se pide el texto que tendrías que poner en tu archivo robots.txt . Las directrices del robots.txt no van en el head, sino en un archivo llamado robots con extensión .txt que debe ir en la carpeta raíz de una web. Esto se explica en la clase.

En la clase se menciona el Crawl Budget que tienen las distintas webs, ¿hay alguna manera de saber cuánto presupuesto asigna Google a una web?

Se puede estimar con los datos de tu servidor o de la search console de la cantidad de url que rastrea Google cuando entra en tu web.

¿El htaccess, no debe tocarse?


Puedes tocarlo, lo importante es hacerlo con cuidado y tener backups.

¿En el caso de BIGSEO Academy, los enlaces a los módulos y demás (enlaces a los que solo interesa acceder con una cuenta) lo marcáis con disallow y no index? o ¿sólo por el hecho de estar protegido con acceso de cuenta sería suficiente?

Sí, está todo protegido con contraseña es más que suficiente. Aunque nunca viene mal marcar un disallow con el robots por si algún enlace o archivo, por error, no estuviera protegido, y para ahorrar crawl budget.

¿Qué ocurre cuando 10 URLs se encuentran en Disallow en el robots.txt para que no genere canibalización ya que son de una subcategoría pero en las URLs se mantiene index, follow y google lo indexa como cualquier otra normal? ¿Puede generar canibalización? ¿cómo afecta a la categoría principal?

```
Disallow: /recreus$
Disallow: /thermal-grizzly$
Disallow: /blu$
Disallow: /nest$
Disallow: /xiaomi/*
Disallow: /asus/*
Disallow: /tp-link/*
Disallow: /apple/*
```



```
Allow: /xiaomi$
Allow: /asus$
Allow: /tp-link$
Allow: /apple$
```

Para que la metaetiqueta noindex surja efecto, no debe haberse bloqueado mediante un archivo robots.txt ni mediante otro mecanismo que impida al rastreador acceder a ella, ya que podría ser que sí está muy enlazada esa página, Google la considere importante y la indexe, incluso aunque no pueda acceder a ella. (Ya que no vería la metaetiqueta noindex, pero ve relevante el contenido.

Esto también se aplica para el canonical. Lo que impides es el rastreo, no la indexación. Por lo que impidiendo el rastreo, tampoco se permiten ver las directivas noindex o las

metaetiquetas como canonical. Entonces os preguntaréis. ¿Por qué entonces si que coge bien el title y la metadescription en el ejemplo de Julio de pccomponentes? Pues muy muy sencillo. Porque el robots de pccomponentes, no está bloqueando dicha URL.

Miradlo bien. Lo que pone en el robots, Impide todo lo que sea pccomponentes.com/xiaomi/* (después de eso, con la barra incluida), pero en el ejemplo:

<https://www.pccomponentes.com/xiaomi-mi-11i-5g-8-128gb-negro-libre> no hay ningún dash.

De hecho si utilizáis la búsqueda con los comandos "site" e "inurl" veréis que no hay nada indexado. Pero podría darse el caso.

ejemplo usando el robots.txt de pccomponentes para que veais que no bloquea ni deja de bloquear la url, traga el allow por defecto.

Edita tu archivo robots.txt y comprueba que no tenga errores. [Más información](#)

Última versión vista el 29/10/21 8:50 Proceso correcto (200) 67 bytes ~ [Ver el archivo robots.txt publicado](#)

```
178 Allow: /seleccion-educacion
179 Disallow: /boletines/*
180 #Disallow: /ofertas/*
181 Disallow: /rec-elec
182
183 # TRACKING CODES
184 Disallow: /*_cn_tracker*
185
186 # BRANDED PAGES AS DUPLICATES
187 Allow: /xiaomi$
188 Allow: /asus$
189 Allow: /tp-link$
190 Allow: /apple$
191 Allow: /lenovo$
192 Allow: /gopro$
```

2 errores 4 advertencias Enviar

<https://bigseo.com/> Googlebot PERMITIDO

Lo podéis observar porque el permitido lo pone suave

<https://www.pccomponentes.com/smartphone-moviles/dual-sim/reacondicionado/xiaomi>

respecto a URL se permite el rastreo, pero por lo mismo que la anterior:

Por defecto

Edita tu archivo robots.txt y comprueba que no tenga errores. [Más información](#)

Última versión vista el 29/10/21 8:50 Proceso correcto (200) 67 bytes ~ [Ver el archivo robots.txt publicado](#)

```
178 Allow: /seleccion-educacion
179 Disallow: /boletines/*
180 #Disallow: /ofertas/*
181 Disallow: /rec-elec
182
183 # TRACKING CODES
184 Disallow: /*_cn_tracker*
185
186 # BRANDED PAGES AS DUPLICATES
187 Allow: /xiaomi$
188 Allow: /asus$
189 Allow: /tp-link$
190 Allow: /apple$
191 Allow: /lenovo$
192 Allow: /gopro$
```

2 errores 4 advertencias Enviar

<https://bigseo.com/> Googlebot PERMITIDO

Otra cosa sería que tuviese el asterisco detrás la línea 187, que entonces si que sería un allow explícito.

Última versión vista el 29/10/21 8:50 Proceso correcto (200) 67 bytes

Ver el archivo robots.txt publicado

```

180 #Disallow: /ofertas/*
181 #Disallow: /rec-elec
182
183 # TRACKING CODES
184 #Disallow: /*?_on_tracker*
185
186 # BRANDED PAGES AS DUPLICATES
187 Allow: /*xiami$
188 Allow: /xiami$
189 Allow: /tp-link$
190 Allow: /apple$
191 Allow: /lenovo$
192 Allow: /gopro$
193 Allow: /msi$
194 Allow: /medion$
  
```

2 errores 4 advertencias

Enviar

https://bigseo.com/ 'smartphone-moviles/dual-sim/reacondicionado/xiaomi' Googlebot PERMITIDO

Respecto al ejemplo de Pc Componente, ¿ cómo se controla las veces que un bot puede pasar a rastrear la web? (aunque para google no tenga efecto). Se ha visto que en pccomponentes sale Disallow: /*/*/* .

Quiere decir, que no quieren que Google les rastree nada que tenga más de 5 Dash (es decir, la barrita esta --> /)

Se adjunta ejemplo:

Probador de robots.txt

Edita tu archivo robots.txt y comprueba que no tenga errores. Más información

Última versión vista el 29/10/21 8:50 Proceso correcto (200) 67 bytes

Ver el archivo robots.txt publicado

```

96 Allow: /privacidad-seguridad-aplicaciones-moviles
97 Disallow: /privacidad
98 Disallow: /aviso-legal
99
100 ## CRAWL BUDGET OPTIMIZATION
101
102 # 34 FILTERS
103 Disallow: /*/*/*/*/*/*
104
105 # QUERIES
106 Disallow: /buscar/?query*
107
108 # AVAILABILITY UX
109 Disallow: /*madrid
110 Disallow: /*murcia
  
```

2 errores 4 advertencias

Enviar


https://bigseo.com/ 'smartphone-moviles/dual-sim/reacondicionado/xiaomi/OTRO-SUBNIVEL-PARA-EJEMPLO-BIGSEO' Googlebot BLOQUEADO

Una web que tiene 2 robots.txt, desde el directorio /shop/ que es la web que más relevancia tiene y sin el directorio. Uno de los robots está dando 4193 órdenes y el otro 63 órdenes (shop). ¿Qué le dirían al cliente en este caso?.

← → ↻ 🔒 motedis.es/shop/robots.txt

```

User-agent: *
Disallow: /shop/*XTCsid
Disallow: /shop/*action=
Disallow: /shop/admin/
Disallow: /shop/cache/
Disallow: /shop/callback/
Disallow: /shop/download/
Disallow: /shop/export/
  
```



```
User-agent: *
Allow: /shop/admin/includes/tools/css/
Allow: /shop/includes/cookie-consent/
Disallow: /shop/*XTCsid
Disallow: /shop/*action=
Disallow: /shop/admin/
Disallow: /shop/cache/
Disallow: /shop/callback/
Disallow: /shop/download/
Disallow: /shop/export/
Disallow: /shop/import/
Disallow: /shop/inc/
Disallow: /shop/includes/
```

Sólo puede haber un archivo robots.txt por sitio. * El archivo robots.txt debe incluirse en la raíz del host del sitio web al que se aplica.

<https://developers.google.com/search/docs/advanced/robots/create-robots-txt?hl=es#:~:text=Solo%20puede%20haber%20un%20archivo.web%20al%20que%20se%20aplica>

Sí hubiera un subdominio, que al ser técnicamente una web distinta, sí puede tener su propio robots.Txt Pero en nuestro caso hablamos de una carpeta dentro de la raíz. Google no le hará caso. Google mirará el root, cogerá el robots.txt correcto y al otro lo ignorará.

Eso debe ser porque la raíz está en un cms y el ecommerce dentro de /shop/ en otro. Es un error, solo debe haber un robots

También tomar en cuenta que debe ser porque la raíz está en un cms y el ecommerce dentro de /shop/ en otro. Es un error, solo debe haber un robots.

Sitemaps

Tengo una web en https:// pero cuando pido el sitemap en yoast me da un http:// ¿por qué?

1. En opciones generales (ubicado en la sección de ajustes), mirar que la dirección de WordPress y que la dirección del sitio esté configurada con https.
2. En Yoast SEO ir al apartado características (ubicado en la sección opciones generales). Desde ahí, desactivar el Sitemap y guardar, después volverlo activarlo para generarlo con https.

Si una web no está hecha con un CMS, ¿cómo se hace el sitemap? ¿con una herramienta?

Es tal cómo son en la web. De hecho los sitemaps son públicos, puedes ver el sitemap de cualquier web cómo lo están haciendo. Debes indicar todas las URLs tal y cómo son.

En cuanto a las webs que no están hechas con un CMS, es decir, que son "desarrollos propios" dependerá de cómo lo haya hecho el desarrollador o la agencia de desarrollo

No es responsabilidad del SEO. Es el desarrollador que le haya vendido la web al cliente el que se tiene que preocupar de tener un sitemap que contenga todas las urls de la web y que esté actualizado.

Como SEO si detectas errores en el Sitemap le tendrás que informar al cliente o directamente al desarrollador que los corrija.

¿Cómo se actualiza continuamente?

En cuanto a actualizarse, sí, debe actualizarse cada vez que haya un cambio en urls, o que haya nuevas o eliminadas. De nuevo, no es nuestra responsabilidad actualizarlo, si no detectar que no está actualizado y a Google Search Console sólo hay que subirlo una vez para que conozca dónde está el sistema y en qué URL.

¿Cómo detectamos lo que no está o sí está actualizado?

Se detecta viendo las alertas de Google Search Console, que te avisa si hay errores y con Search Console también se analiza y el momento en el que se detecta es, efectivamente, haciendo la Auditoría SEO pero las formas de detectarlos son esas dos.

Sin embargo es necesario saber cómo funciona un sitemap por varios motivos.

Primero, porque incluso ciertos plugins de renombre que hacen sitemaps automáticos, los hacen de forma incorrecta, metiendo duplicados y páginas de no interés. Segundo, porque aquí os preparamos para cualquier tipo de situación SEO, y hay en empresas con su software

propio que necesitan automatizar lo del sitemap. La función del SEO no es hacerlo automático, pero sí es verificar que el sitemap que se genera es correcto. Se envía un ejemplo práctico, de empresas grandes que tienen seos y que necesitan estas verificaciones: