

ROBOTS.TXT

MasterSEO
by BIGSEO

TU CAM

ROBOTS.TXT

ÍNDICE

Qué son los robots.txt

Qué función cumplen

Cómo optimizar los archivos

MasterSEO
by BIGSEO

TU CAM

¿Qué es un archivo robots.txt?

Un archivo robots.txt indica a los rastreadores de los buscadores qué páginas o archivos de tu sitio pueden solicitar y cuáles no.

Funciones de los Robots.txt

TU CAM

Principalmente, se utilizan para evitar que las solicitudes que recibe tu sitio lo sobrecarguen.

Con robots.txt podemos controlar

Rastreo



Indexación



TU CAM

Combinar el rastreo con las directivas para indexar y servir contenido

Las metaetiquetas “robots” y las cabeceras HTTP se descubren al **rastrear una URL**.

Si no se permite rastrear una página a través del archivo robots.txt, no se podrá encontrar ninguna información sobre directivas para indexar y servir contenido, y la página se ignorará.


Si se deben seguir directivas para indexar o servir contenido, no se debe impedir el rastreo de las URLs que contengan esas directivas.

Podemos controlar el rastreo de:

Página/s Webs



Archivo/s multimedia



Archivo/s de recursos



TU CAM

Limitaciones del archivo robots.txt

- Directivas no compatibles con otros buscadores
- Sintaxis interpretadas diferente según buscador
- Indexaciones de URLs por enlaces externos

TU CAM



En respuesta a @chowell18

URLs can be indexed without being crawled, if they're blocked by robots.txt - that's by design. Usually that comes from links from somewhere, judging from that number, I'd imagine from within your site somewhere.

[Traducir Tweet](#)

11:09 p. m. · 26 mar. 2019 · [TweetDeck](#)

Search result title
<https://www.example.com>



En respuesta a @chowell18

The titles generally come from links - they shouldn't have a snippet though. Happy to take a look if you drop me the URLs!

[Traducir Tweet](#)

11:27 a. m. · 27 mar. 2019 · [Twitter Web Client](#)

TU CAM

No hay información de la página en los resultados

Es posible que en un resultado de búsqueda de Google se indique que no hay información disponible sobre una página web.



TU CAM

**Si tu página web está bloqueada
por un archivo robots.txt...**

Podrá seguir apareciendo en los resultados de búsqueda, pero **sin ninguna descripción**.

Se excluirán los archivos de imagen y vídeo, así como los archivos PDF y todo aquello que no sea HTML.

Formato y ubicación de los Robots.txt

TU CAM

Reglas de formato y ubicación

El archivo debe llamarse robots.txt.

`https://tudominio.com/robots.txt`

TU CAM

Reglas de formato y ubicación

Solo puede haber un archivo robots.txt por sitio web.



TU CAM

Reglas de formato y ubicación

El archivo robots.txt debe incluirse en la raíz del host del sitio web al que se aplica. Por ejemplo, para controlar el rastreo de todas las URL de <http://www.example.com/>, el archivo robots.txt debe estar en <http://www.example.com/robots.txt> y no en un subdirectorío como, por ejemplo, <http://example.com/páginas/robots.txt>.

Si no sabes con seguridad cómo acceder a la raíz de tu sitio web o necesitas permisos para hacerlo, ponte en contacto con tu proveedor de servicios de alojamiento web. Si no puedes acceder a la raíz, utiliza un método de bloqueo alternativo, como las [metaetiquetas](#).

TU CAM

Reglas de formato y ubicación

Los archivos robots.txt se pueden aplicar a subdominios, como <http://sitioweb.example.com/robots.txt>, y a puertos no estándar, como <http://example.com:8181/robots.txt>.

STATUS 2XX

URL 1
URL 2
URL 3
URL 4
URL 5
URL 6
URL 7
URL 8
URL 9
URL 10

STATUS 4XX

URL 1
URL 2
URL 3
URL 4
URL 5
URL 6
URL 7
URL 8
URL 9
URL 10

STATUS 5XX

URL 1
URL 2
URL 3
URL 4
URL 5
URL 6
URL 7
URL 8
URL 9
URL 10

Sintaxis

Los archivos robots.txt deben estar codificados en UTF-8, que incluye ASCII. No se pueden utilizar otros conjuntos de caracteres.

Los archivos robots.txt constan de uno o varios grupos.

Cada grupo consta de varias reglas o directivas (instrucciones). Debe añadirse una directiva por línea.

En un grupo se proporciona la siguiente información:

- A quién se aplica el grupo; el user-agent.
- A qué directorios o archivos puede acceder ese user-agent.
- A qué directorios o archivos no puede acceder ese user-agent.

TU CAM

Sintaxis

Los grupos se procesan en el orden en que aparecen en el texto. Los user-agent solo siguen las directivas de un grupo, que será el primero que incluya la regla más específica que coincida con el user-agent en cuestión.

De forma predeterminada, los user-agent pueden rastrear todas las páginas y directorios que no estén bloqueados por una regla **Disallow**.

El sistema de las reglas distingue entre mayúsculas y minúsculas. Por ejemplo, la regla **Disallow:/file.asp** se aplica a <http://www.example.com/file.asp> pero no a <http://www.example.com/FILE.asp>.

TU CAM

Referencias

User-agent:

Crawl-delay:

Sitemap:

Permisos

Allow:

Disallow:

Caracteres especiales

*

\$

#

user-agent

user-agent: *

user-agent: googlebot

user-agent: googlebot-news

allow

allow: /

allow: /noticias/

allow: /noticias/deportes/

allow: /noticias/deportes/\$

allow: /noti*

allow: /*.gif\$

sitemap

sitemap: https://tudominio.com/sitemap_index.xml

sitemap: <https://tudominio.com/sitemap.xml>

disallow

disallow: /

disallow: /?id=*

disallow: /archivo.pdf

disallow: /busquedas/

disallow: /busquedas/\$

disallow: /noticias/sucesos/

disallow: /wp-*/\$

Sitemap: <https://www.mediamarkt.es/sitemap/siteindex.xml>
Sitemap: <https://www.mediamarkt.es/sitemap-generic-pages.xml>
Sitemap: https://www.mediamarkt.es/sitemap_cleaning.xml

User-Agent: *

Disallow: /webapp/wcs/stores/servlet/LogonForm
Disallow: /webapp/wcs/stores/servlet/MultiChannelMANewsletterRegister
Disallow: /webapp/wcs/stores/servlet/MultiChannelMAContact
Disallow: /webapp/wcs/stores/servlet/MultiChannelMAGiftCard
Disallow: /webapp/wcs/stores/servlet/MultiChannelMARepairStatus
Disallow: /webapp/wcs/stores/servlet/MultiChannelMASearchOrderForGuestUser
Disallow: /webapp/wcs/stores/servlet/MultiChannelMAMasterData
Disallow: /webapp/wcs/stores/servlet/MultiChannelMAPersonal
Disallow: /webapp/wcs/stores/servlet/MultiChannelMAChangePassword
Disallow: /error404.html
Disallow: /error500.html
Disallow: /*storeId=*

Disallow: /MultiChannelMA
Disallow: /MultiChannelLocal
Disallow: /MultiChannelSearch
Disallow: /MultiChannelRedirect
Disallow: /MultiChannelMARegister
Disallow: /MultiChannelMyStoreEvents
Disallow: /MultiChannelAutoCompletion
Disallow: /MultiChannelCatalogEntryPrint
Disallow: /MultiChannelPrintCompProducts
Disallow: /MultiChannelMyStoreAdvertising
Disallow: /MultiChannelMyStoreSpecialItems
Disallow: /MultiMultiChannelMAWishlistPrint
Disallow: /mediapedia
Disallow: /error404.html
Disallow: /error500.html
Disallow: /*storeId=*

Allow: /*storeId=19601*

TU CAM

```
user-agent: googlebot-news  
(group 1)
```

```
user-agent: *  
(group 2)
```

```
user-agent: googlebot  
(group 3)
```



Los rastreadores elegirían el grupo pertinente del siguiente modo:

Grupo seguido por un rastreador	
Robot de Google para Noticias	Se sigue el grupo 1. Solo se sigue el grupo más específico; el resto se ignora.
Robot de Google (Web)	Se sigue el grupo 3.
Robot de Google para Imágenes	Se sigue el grupo 3. No hay ningún grupo que especifique googlebot-images , por lo que se sigue el grupo más genérico.
Googlebot-News (cuando se rastrean imágenes)	Se sigue el grupo 1. Es el Robot de Google para Noticias el que rastrea las imágenes, por lo que solo se sigue el grupo de ese robot.
Otros robots (Web)	Se sigue el grupo 2.
Otros robots (Noticias)	Se sigue el grupo 2. Aunque haya una entrada de un rastreador relacionado, solo se siguen las que coinciden de forma específica.

TU CAM

Orden de prioridad de líneas de miembros de grupos

A nivel de miembro de grupo, en particular para las directivas allow y disallow, la regla más específica en función de la longitud de la entrada [path] prevalece sobre la menos específica (más corta). En caso de reglas en conflicto, incluidas las que tienen comodines, se utiliza la reglas menos restrictiva.

```
http://example.com/
```

```
allow: /$
```

```
disallow: /
```

```
Resultado: allow
```

```
http://example.com/folder/page
```

```
allow: /folder
```

```
disallow: /folder
```

```
Resultado: allow
```

TU CAM

Probador de robots.txt

Edita tu archivo robots.txt y comprueba que no tenga errores. [Más información](#)

Última versión vista el 9/7/21 7:37 Proceso correcto (200) 627 bytes ▾

[Ver el archivo robots.txt publicado](#)

```
1 User-agent: *
2 Disallow: /wp-admin/
3 Allow: /wp-admin/admin-ajax.php
4
5 User-Agent: Googlebot
6 Allow: /*.css$
7 Allow: /*.js$
8
9 User-agent: *
10 Disallow: /?s=
11 Disallow: /search
12
13 User-agent: *
14 Disallow: /trackback
15 Disallow: /*trackback
```

✖ 0 errores ⚠ 0 advertencias

Enviar

https://carlosortega.page/

Googlebot ▾

PROBAR

TU CAM

Test and validate your robots.txt with this testing tool. Check if a URL is blocked, which statement is blocking it and for which user agent. You can also check if the resources for the page (CSS, JavaScript, images) are disallowed.

URL	User Agent Googlebot Smartphone	☐ Live ☒ Editor	☒ Check Resources	TEST
<pre>14 Disallow: /trackback 15 Disallow: /*trackback 16 Disallow: /*trackback* 17 Disallow: /*/trackback 18 19 User-agent: * 20 Allow: /feed/\$ 21 Disallow: /feed/ 22 Disallow: /comments/feed/ 23 Disallow: /*/feed/\$ 24 Disallow: /*/feed/rss/\$ 25 Disallow: /*/trackback/\$ 26 Disallow: /*/*/feed/\$ 27 Disallow: /*/*/feed/rss/\$ 28 Disallow: /*/*/trackback/\$ 29 Disallow: /*/*/*/feed/\$ 30 Disallow: /*/*/*/feed/rss/\$ 31 Disallow: /*/*/*/trackback/\$ 32 33 Sitemap: https://carlosortega.page/sitemap.xml</pre>				

TU CAM

¡MUCHAS GRACIAS!

TU CAM