

ANÁLISIS DE LOGS

MasterSEO
by BIGSEO

TU CAM

ANÁLISIS DE LOGS

ÍNDICE

Introducción

Logs del servidor

Preparar los datos

Análisis de datos

MasterSEO
by BIGSEO

TU CAM

INTRODUCCIÓN

¿Qué es el análisis de logs?

Consiste en analizar los datos de diferentes archivos que se crean y almacenan en el servidor con diferentes objetivos:

- Control de performance
- Q&A
- Análisis de comportamiento de bots
- Ver qué errores están apareciendo en un site
- ...

```
192.168.1.1 - - [11/Oct/2018:11:36:24 +0200] "GET /index.php/apps
192.168.1.1 - - [11/Oct/2018:11:36:25 +0200] "GET /index.php/apps
192.168.1.1 - - [11/Oct/2018:11:36:25 +0200] "GET /index.php/apps
192.168.1.1 - - [11/Oct/2018:11:36:27 +0200] "GET /index.php/apps
192.168.1.1 - - [11/Oct/2018:11:36:28 +0200] "GET /index.php/apps
192.168.1.1 - - [11/Oct/2018:11:36:29 +0200] "GET /index.php/apps
192.168.1.1 - - [11/Oct/2018:11:36:31 +0200] "GET /index.php/apps
192.168.1.1 - - [11/Oct/2018:11:36:32 +0200] "GET /index.php/apps
192.168.1.1 - - [11/Oct/2018:11:36:32 +0200] "GET /index.php/apps
192.168.1.1 - - [11/Oct/2018:11:36:34 +0200] "GET /index.php/apps
192.168.1.1 - - [11/Oct/2018:11:36:35 +0200] "GET /index.php/apps
192.168.1.1 - - [11/Oct/2018:11:36:35 +0200] "GET /index.php/apps
192.168.1.1 - - [11/Oct/2018:11:36:37 +0200] "GET /index.php/apps
192.168.1.1 - - [11/Oct/2018:11:36:39 +0200] "GET /index.php/apps
192.168.1.1 - - [11/Oct/2018:11:36:39 +0200] "GET /index.php/apps
192.168.1.1 - - [11/Oct/2018:11:36:40 +0200] "GET /index.php/apps
192.168.1.1 - - [11/Oct/2018:11:36:42 +0200] "GET /index.php/apps
192.168.1.1 - - [11/Oct/2018:11:36:42 +0200] "GET /index.php/apps
192.168.1.1 - - [11/Oct/2018:11:36:44 +0200] "GET /index.php/apps
192.168.1.1 - - [11/Oct/2018:11:36:46 +0200] "GET /index.php/apps
192.168.1.1 - - [11/Oct/2018:11:36:46 +0200] "GET /index.php/apps
192.168.1.1 - - [11/Oct/2018:11:36:47 +0200] "GET /index.php/apps
```

TU CAM

TU CAM

**Nos interesa lo que sucede en el lado del
servidor**

TU CAM


LOGS DEL SERVIDOR

¿Qué es un archivo de logs?

También conocido como logfile.

- Es un archivo de texto plano donde se almacenan todos los eventos que ocurren dentro de un servidor, software o sistema operativo
- Depende del evento, encontramos diferentes tipos de logs:
 - Access logs
 - Error logs
 - System logs
 - ...

TU CAM



Access logs

En este archivo se registran todos los eventos de tipo “Access” o “Request” de una aplicación/site.

- En este tipo de logs podremos ver todas las peticiones de cualquier ente (sea humano u bot) a cualquier documento
- El análisis de logs se basa principalmente en este archivo

TU CAM

Error log

Archivo donde se almacenan todos los errores relacionados con la aplicación en sí.

- El tipo de errores que puedes encontrar depende de la configuración de la aplicación
- Un error de server (5xx status code) se pueden debugger usando este tipo de logs

PHP Error Log	
Jul 16, 17:30:51	PHP 5. ErrorLogDashboardWidget->handleSettingsForm() \wp-admin\includes\dashboard.php:0
Jul 16, 17:30:51	PHP 6. scbCron->reschedule() \wp-content\plugins\error-log-monitor\plugin.php:172
Jul 16, 17:30:51	PHP Notice: Undefined variable: time in \wp-content\plugins\error-log-monitor\scbCron.php on line 76
Jul 16, 17:30:51	PHP Stack trace:
Jul 16, 17:30:51	PHP 1. {main}() \wp-admin\index.php:0
Jul 16, 17:30:51	PHP 2. wp_dashboard_setup() \wp-admin\index.php:15
Jul 16, 17:30:51	PHP 3. wp_dashboard_trigger_widget_control() \wp-admin\includes\dashboard.php:135
Jul 16, 17:30:51	PHP 4. call_user_func() \wp-admin\includes\dashboard.php:1049
Jul 16, 17:30:51	PHP 5. ErrorLogDashboardWidget->handleSettingsForm() \wp-admin\includes\dashboard.php:0
Jul 16, 17:30:51	PHP 6. scbCron->reschedule() \wp-content\plugins\error-log-monitor\plugin.php:172
Log file: C:\xampp\htdocs\cbtool\blog\wp-content\debug.log (1.81 KiB) Clear Log	

TU CAM

System logs

Logs de un sistema operativo, como puede ser tu Windows, Mac o Linux

- Se registran todos los eventos relacionados con nuestro ordenador
- En Mac podemos acceder a ellos a través de la terminal:
 - Usando el comando *log show*
 - Podemos interactuar con esta información usando la terminal

```
08-10 08:20:31.919050+0200 0x17f Default 0x0 450 0 ManagedClient: [com.apple.ManagedClient:ManagedClient] MCK_handleComputerProfiles scanning installed provisioning files...
08-10 08:20:31.919853+0200 0x17f Default 0x0 450 0 ManagedClient: [com.apple.ManagedClient:ManagedClient] MCK_configureDataProfilesForAllUsersASCPProfile ALL profile (ETHER config or prov profiles)
08-10 08:20:31.919897+0200 0x17f Default 0x0 450 0 ManagedClient: [com.apple.ManagedClient:ManagedClient] MCK_configureDataProfilesForAllUsersASCPProfile return zero files (ETHER config or prov profiles)
08-10 08:20:31.920796+0200 0x17f Activity 0x1d30 452 0 MCKCompositor: (CoreFoundation) Notifying CFPrefSD of Updated Managed Preferences
08-10 08:20:31.922236+0200 0x17f Activity 0x1d31 452 0 MCKCompositor: (CoreFoundation) Notifying CFPrefSD of Updated Managed Preferences
08-10 08:20:31.924042+0200 0x17f Activity 0x1d40 372 0 corecaptured: (CoreFoundation) Resetting CFPrefPreferences/NSUserDefaults
08-10 08:20:31.925717+0200 0x17f Activity 0x1d32 452 0 MCKCompositor: (CoreFoundation) Notifying CFPrefSD of Updated Managed Preferences
08-10 08:20:31.929656+0200 0x17f Activity 0x1d33 452 0 MCKCompositor: (CoreFoundation) Notifying CFPrefSD of Updated Managed Preferences
08-10 08:20:31.930215+0200 0x17f Error 0x0 152 0 appsd: [com.apple.appsd:preference] -privates: Preferences may have changed, checking for any relevant changes
08-10 08:20:31.930803+0200 0x17f Activity 0x1d34 452 0 MCKCompositor: (CoreFoundation) Notifying CFPrefSD of Updated Managed Preferences
08-10 08:20:31.930882+0200 0x17f Error 0x0 152 0 appsd: [com.apple.appsd:preference] -privates: Preferences may have changed, checking for any relevant changes
08-10 08:20:31.931101+0200 0x17f Activity 0x1d35 452 0 MCKCompositor: (CoreFoundation) Notifying CFPrefSD of Updated Managed Preferences
08-10 08:20:31.931151+0200 0x17f Activity 0x1d41 372 0 corecaptured: (CoreFoundation) Resetting CFPrefPreferences/NSUserDefaults
08-10 08:20:31.931188+0200 0x17f Activity 0x1d42 372 0 corecaptured: (CoreFoundation) Resetting CFPrefPreferences/NSUserDefaults
08-10 08:20:31.931319+0200 0x17f Activity 0x1d20 152 0 appsd: (CoreFoundation) Loading Preferences From System CFPrefSD
08-10 08:20:31.931476+0200 0x17f Activity 0x1d21 152 0 appsd: (CoreFoundation) Loading Preferences From System CFPrefSD
08-10 08:20:31.931717+0200 0x17f Activity 0x1d22 152 0 MCKCompositor: (CoreFoundation) Notifying CFPrefSD of Updated Managed Preferences
08-10 08:20:31.931866+0200 0x17f Activity 0x1d36 452 0 MCKCompositor: (CoreFoundation) Notifying CFPrefSD of Updated Managed Preferences
08-10 08:20:31.932097+0200 0x17f Activity 0x1d37 452 0 appsd: (CoreFoundation) Loading Preferences From System CFPrefSD
08-10 08:20:31.932189+0200 0x17f Activity 0x1d23 152 0 appsd: (CoreFoundation) Loading Preferences From System CFPrefSD
08-10 08:20:31.932313+0200 0x17f Activity 0x1d24 152 0 appsd: (CoreFoundation) Loading Preferences From System CFPrefSD
08-10 08:20:31.932337+0200 0x17f Activity 0x1d25 152 0 appsd: (CoreFoundation) Loading Preferences From System CFPrefSD
08-10 08:20:31.932853+0200 0x17f Activity 0x1d38 452 0 MCKCompositor: (CoreFoundation) Notifying CFPrefSD of Updated Managed Preferences
08-10 08:20:31.932867+0200 0x17f Error 0x0 152 0 appsd: [com.apple.appsd:preference] -privates: Preferences may have changed, checking for any relevant changes
08-10 08:20:31.933060+0200 0x17f Activity 0x1d39 452 0 MCKCompositor: (CoreFoundation) Notifying CFPrefSD of Updated Managed Preferences
08-10 08:20:31.933216+0200 0x17f Activity 0x1d26 152 0 appsd: (CoreFoundation) Loading Preferences From System CFPrefSD
08-10 08:20:31.933347+0200 0x17f Activity 0x1d27 152 0 appsd: (CoreFoundation) Loading Preferences From System CFPrefSD
08-10 08:20:31.933400+0200 0x17f Activity 0x1d28 152 0 appsd: (CoreFoundation) Loading Preferences From System CFPrefSD
08-10 08:20:31.933795+0200 0x17f Error 0x0 152 0 appsd: [com.apple.appsd:preference] -privates: Preferences may have changed, checking for any relevant changes
08-10 08:20:31.933881+0200 0x17f Activity 0x1d3a 452 0 MCKCompositor: (CoreFoundation) Notifying CFPrefSD of Updated Managed Preferences
08-10 08:20:31.933886+0200 0x17f Activity 0x1d3b 452 0 MCKCompositor: (CoreFoundation) Notifying CFPrefSD of Updated Managed Preferences
08-10 08:20:31.934086+0200 0x17f Activity 0x1d29 152 0 appsd: (CoreFoundation) Loading Preferences From System CFPrefSD
08-10 08:20:31.934159+0200 0x17f Error 0x0 452 0 MCKCompositor: (CoreFoundation) Detected potentially harmful notification post rate of 2211.5 notifications per second
08-10 08:20:31.934215+0200 0x17f Activity 0x1d2a 152 0 appsd: (CoreFoundation) Loading Preferences From System CFPrefSD
08-10 08:20:31.934461+0200 0x17f Activity 0x1d2b 152 0 appsd: (CoreFoundation) Loading Preferences From System CFPrefSD
08-10 08:20:31.934750+0200 0x17f Error 0x0 152 0 appsd: [com.apple.appsd:preference] -privates: Preferences may have changed, checking for any relevant changes
08-10 08:20:31.934767+0200 0x17f Activity 0x1d3c 452 0 MCKCompositor: (CoreFoundation) Notifying CFPrefSD of Updated Managed Preferences
08-10 08:20:31.934954+0200 0x17f Activity 0x1d3d 452 0 MCKCompositor: (CoreFoundation) Notifying CFPrefSD of Updated Managed Preferences
08-10 08:20:31.935040+0200 0x17f Activity 0x1d2c 152 0 appsd: (CoreFoundation) Loading Preferences From System CFPrefSD
08-10 08:20:31.935178+0200 0x17f Activity 0x1d2e 152 0 appsd: (CoreFoundation) Loading Preferences From System CFPrefSD
08-10 08:20:31.936262+0200 0x17f Activity 0x1d60 152 0 appsd: (CoreFoundation) Loading Preferences From System CFPrefSD
08-10 08:20:31.936485+0200 0x17f Activity 0x1d61 152 0 appsd: (CoreFoundation) Loading Preferences From System CFPrefSD
08-10 08:20:31.936486+0200 0x17f Activity 0x1d59 452 0 MCKCompositor: (CoreFoundation) Notifying CFPrefSD of Updated Managed Preferences
08-10 08:20:31.936739+0200 0x17f Activity 0x1d43 372 0 corecaptured: (CoreFoundation) Resetting CFPrefPreferences/NSUserDefaults
08-10 08:20:31.936760+0200 0x17f Error 0x0 152 0 appsd: [com.apple.appsd:preference] -privates: Preferences may have changed, checking for any relevant changes
08-10 08:20:31.936831+0200 0x17f Activity 0x1d44 372 0 corecaptured: (CoreFoundation) Resetting CFPrefPreferences/NSUserDefaults
08-11 08:59:17.667297+0200 0x17f Timesync 0x0 0 0 == system boot: BF19EC53-4396-4DA2-B2C2-8FA147087E9B
- Default: 66,196, Info: 0, Debug: 0, Error: 2,949, Fault: 5
ity = Create: 5,787, Transition: 0, Actions: 0
```

```
nacho.mas cort@ST-A210-95QLVDL ~ log show --last 4d | grep -E "=== system boot: [Previous shutdown cause: 5]"
2021-09-06 09:34:09.975250+0200 0x0 Timesync 0x0 0 0 === system boot: 05DA9FA8-1395-407B-BEB8-4E09F70EAB7E
2021-09-06 09:34:10.529141+0200 0xc0 Default 0x0 0 0 kernel: (AppleSMC) Previous shutdown cause: 5
```

Formato de un Access log



TU CAM

Formato de un Access log (Apache Common log format)

```
1 37.59.226.80 - - [08/Sep/2021:14:12:44 +0200] "POST /wp-cron.php?doing_wp_cron=1631103164.5560739040374755859375 HTTP/1.1" 200 0 "https://seohacks.es/wp-cron.php"
2 66.249.66.211 - - [08/Sep/2021:14:12:43 +0200] "GET /ddos/amp/ HTTP/2" 200 15774 "-" "Mozilla/5.0 (Linux; Android 6.0.1; Nexus 5X Build/MMB29P) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/90.0.4431.95 Mobile Safari/537.36"
3 54.144.223.204 - - [08/Sep/2021:14:16:54 +0200] "GET /creando-blog-seo-wordpress/feed/ HTTP/2" 304 0 "https://www.google.com/" "Mozilla/5.0 (Macintosh; Intel Mac OS X 10_15_7) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/90.0.4431.95 Safari/537.36"
4 54.82.9.56 - - [08/Sep/2021:14:21:47 +0200] "GET /cloaking/feed/ HTTP/2" 304 0 "https://www.google.com/" "Mozilla/5.0 (Windows NT 10.0; rv:68.0) Gecko/20100101 Firefox/68.0"
5 188.165.213.192 - - [08/Sep/2021:14:25:18 +0200] "HEAD / HTTP/2" 200 0 "https://seohacks.es/" "Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/90.0.4431.95 Safari/537.36"
6 150.95.110.113 - - [08/Sep/2021:14:25:36 +0200] "GET /wp-login.php HTTP/2" 302 683 "http://seohacks.es/wp-login.php" "Mozilla/5.0 (X11; Ubuntu; Linux x86_64; rv:68.0) Gecko/20100101 Firefox/68.0"
7 79.157.216.33 - - [08/Sep/2021:14:31:11 +0200] "GET /guia-seo/tf-idf-texttrank-seo/ HTTP/2" 200 10775 "-" "Mozilla/5.0 (Macintosh; Intel Mac OS X 10_15_7) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/90.0.4431.95 Safari/537.36"
8 37.59.226.80 - - [08/Sep/2021:14:35:34 +0200] "POST /wp-cron.php?doing_wp_cron=1631104534.6066679954528808593750 HTTP/1.1" 200 0 "https://seohacks.es/wp-cron.php"
9 100.26.50.38 - - [08/Sep/2021:14:35:34 +0200] "GET /feed/ HTTP/2" 304 0 "https://www.google.com/" "Mozilla/5.0 (X11; Linux x86_64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/90.0.4431.95 Safari/537.36"
10 80.42.214.159 - - [08/Sep/2021:14:37:27 +0200] "GET / HTTP/2" 200 16098 "https://github.com/" "Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/90.0.4431.95 Safari/537.36"
11 80.42.214.159 - - [08/Sep/2021:14:37:27 +0200] "GET /wp-content/plugins/wp-gdpr-compliance/assets/css/front.css?ver=1560947218 HTTP/2" 200 2219 "https://seohacks.es/"
12 80.42.214.159 - - [08/Sep/2021:14:37:27 +0200] "GET /wp-content/themes/sparkling/assets/js/functions.js?ver=20180503 HTTP/2" 200 1013 "https://seohacks.es/" "Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/90.0.4431.95 Safari/537.36"
13 80.42.214.159 - - [08/Sep/2021:14:37:27 +0200] "GET /wp-content/plugins/another-stars-rating/css/yasr-table-light.css?ver=2.2.7 HTTP/2" 200 404 "https://seohacks.es/"
14 80.42.214.159 - - [08/Sep/2021:14:37:27 +0200] "GET /wp-content/plugins/fancier-author-box/js/ts-fab.min.js?ver=1.4 HTTP/2" 200 267 "https://seohacks.es/" "Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/90.0.4431.95 Safari/537.36"
15 80.42.214.159 - - [08/Sep/2021:14:37:27 +0200] "GET /wp-content/plugins/cookie-notice/css/front.min.css?ver=5.0.13 HTTP/2" 200 1575 "https://seohacks.es/" "Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/90.0.4431.95 Safari/537.36"
16 80.42.214.159 - - [08/Sep/2021:14:37:27 +0200] "GET /wp-content/plugins/another-stars-rating/css/yasr.css?ver=2.2.7 HTTP/2" 200 1398 "https://seohacks.es/" "Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/90.0.4431.95 Safari/537.36"
17 80.42.214.159 - - [08/Sep/2021:14:37:27 +0200] "GET /wp-content/plugins/contact-form-7/includes/css/styles.css?ver=5.1.7 HTTP/2" 200 725 "https://seohacks.es/" "Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/90.0.4431.95 Safari/537.36"
18 80.42.214.159 - - [08/Sep/2021:14:37:27 +0200] "GET /wp-content/plugins/easy-bootstrap-shortcodes/styles/font-awesome.min.css?ver=5.0.13 HTTP/2" 200 5533 "https://seohacks.es/"
19 80.42.214.159 - - [08/Sep/2021:14:37:27 +0200] "GET /wp-content/themes/sparkling/assets/js/vendor/bootstrap.min.js?ver=5.0.13 HTTP/2" 200 11529 "https://seohacks.es/"
20 80.42.214.159 - - [08/Sep/2021:14:37:27 +0200] "GET /wp-includes/css/dashicons.min.css?ver=5.0.13 HTTP/2" 200 28902 "https://seohacks.es/" "Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/90.0.4431.95 Safari/537.36"
```

Formato de un Access log (Apache Common log format)

```
54.144.223.204 - - [08/Sep/2021:14:16:54 +0200] "GET  
/creando-blog-seo-wordpress/feed/ HTTP/2" 304 0 "https://www.google.com/"  
"Mozilla/5.0 (Macintosh; Intel Mac OS X 10_15_3) AppleWebKit/537.36 (KHTML,  
like Gecko) Chrome/80.0.3987.132 Safari/537.36"
```

TU CAM

Formato de un Access log (Apache Common log format)

```
54.144.223.204 - - [08/Sep/2021:14:16:54 +0200] "GET  
/creando-blog-seo-wordpress/feed/ HTTP/2" 304 0 "https://www.google.com/"  
"Mozilla/5.0 (Macintosh; Intel Mac OS X 10_15_3) AppleWebKit/537.36 (KHTML,  
like Gecko) Chrome/80.0.3987.132 Safari/537.36"
```

TU CAM

IP

Dirección IP desde donde se realiza la petición

Puede ser usado para:

- Verificar ciertos bots (reverse DNS)
- Buscar patrones en un ataque DoS o DDoS

Si un proxy hace la petición veremos la IP del proxy


54.144.223.204

TU CAM

Protocolo de identificación

Método de apache para identificar ciertas conexiones


- Rara vez encontrarás información aquí (desde un motor de búsqueda, nunca)



TU CAM

Usuario

Si el documento al que se intenta acceder está protegido por contraseña, un usuario aparecerá en esta parte, sino un guión por no ser necesario



TU CAM

Fecha y hora de la petición

Fecha, hora y diferencia horaria
de la petición

[día/mes/año:hora:minuto:segundo zona]

- Día: 2 dígitos
- Mes: 3 letras
- Año: 4 dígitos
- Hora: 2 dígitos
- Minuto: 2 dígitos
- Segundo: 2 dígitos
- Zona: (+ | -) 4 digitos

[08/Sep/2021:14:16:54 +0200]

TU CAM

Método, URL y protocolo

- Método usado durante la petición
- URL que se ha pedido
- Protocolo usado

"GET /creando-blog-seo-wordpress/feed/ HTTP/2"

TU CAM

Métodos existentes (más comunes)

Método	Descripción
GET	Realiza una petición de datos o un documento
HEAD	Igual que GET pero sin pedir el body del documento
DELETE	Para eliminar un recurso
POST	Usado para modificar o enviar información (Un formulario)

TU CAM


Versión del protocolo

Existen varias versiones:

- HTTP/1.1
- HTTP/2
- HTTP/3

La mitad de las requests que realiza Googlebot las hace mediante HTTP/2

- 60% Reducción en conexiones y ancho de banda



TU CAM

Código de estado

Código que devuelve el servidor para indicar el estado de esa URL durante una request

304

TU CAM

Códigos de estado

- Informativa → 100 - 199
- Éxito → 200 - 299
- Redirecciones → 300 - 399
- Errores de cliente → 400 - 499
- Errores de servidor → 500 - 599

TU CAM

Los que hemos de conocer sí o sí

- 200 → Success
- 301 → Permanent redirect
- 302 → Temporary redirect
- 304 → Not modified
- 307 → Temporary redirect (HSTS)
- 401 → Unauthorized
- 403 → Forbidden
- 404 → Not found
- 410 → Gone
- 418 → I'm a teapot
- 429 → Too many requests
- 500 → Internal server error
- 503 → Service unavailable (Retry-After)

TU CAM

Tamaño en bytes

Tamaño en bytes de la descarga del documento

- En este caso es cero porque el body no se descarga debido al status 304

0

TU CAM

Origen / referrer

En caso de que la sesión venga de otra página se muestra el origen

- Si es de otro dominio solo se muestra el dominio
- Si es del mismo dominio se muestra la ruta

"https://www.google.com/"

TU CAM

User-agent

Texto que “identifica” quién hace la request.

Es una manera de identificar:

- Dispositivo
- Navegador y versión
- Bot
- ...

Es muy fácil de *fakear*

```
"Mozilla/5.0 (Macintosh; Intel Mac OS X 10_15_3)
AppleWebKit/537.36 (KHTML, like Gecko)
Chrome/80.0.3987.132 Safari/537.36"
```

TU CAM

User-agents a tener en cuenta

Googlebot Image	User agent tokens	• Googlebot-Image • Googlebot
	Full user agent string	Googlebot-Image/1.0
Googlebot News	User agent tokens	• Googlebot-News • Googlebot
	Full user agent string	Googlebot-News
Googlebot Video	User agent tokens	• Googlebot-Video • Googlebot
	Full user agent string	Googlebot-Video/1.0
Googlebot Desktop	User agent token	Googlebot
	Full user agent strings	• Mozilla/5.0 (compatible; Googlebot/2.1; +http://www.google.com/bot.html) • Mozilla/5.0 AppleWebKit/537.36 (KHTML, like Gecko Googlebot/2.1; +http://www.google.com/bot.html) Safari/537.36 • Googlebot/2.1 (+http://www.google.com/bot.html)
Googlebot Smartphone	User agent token	Googlebot
	Full user agent string	Mozilla/5.0 (Linux; Android 6.0.1; Nexus 5X Build 537.36 (KHTML, like Gecko) Chrome/W.X.Y.Z Mobile (compatible; Googlebot/2.1; + http://www.google.co
Mobile AdSense 	User agent token	Mediapartners-Google
	Full user agent string	(Various mobile device types) (compatible; Mediapartners-Google/2.1; + http://www.google.com/bot.html)

- Googlebot
- Semrushbot
- Ahrefsbot
- Bingbot
- ...


TU CAM

Podemos ver las request desde el navegador

Name	Method	Status	Protocol	Type	Initiator	Size	Time
skype.softonic.com	GET	200	h2	document	Other	43.1 kB	142 ms
skype-logo.png	GET	200	h2	webp	(index)	2.4 kB	38 ms
61467-43374.woff2	GET	200	h2	font	(index)	21.5 kB	32 ms
e1d66-c2268.css	GET	200	h2	stylesheet	(index)	18.0 kB	35 ms
40150-b79a7.css	GET	200	h2	stylesheet	(index)	2.2 kB	36 ms
72c3f-d7d93.mjs	GET	200	h2	script	(index)	25.1 kB	34 ms
23986-8effe.mjs	GET	200	h2	script	(index)	18.1 kB	34 ms
loader.js?target=softonic.com	GET	200	h2	script	(index)	17.4 kB	29 ms
gtm.js?id=GTM-5LWWHP	GET	200	h3	script	(index)	81.5 kB	79 ms
gpt.js	GET	200	h3	script	(index)	25.0 kB	94 ms
js?id=AW-631321069	GET	200	h3	script	(index)	39.3 kB	58 ms
c6dac-21cbb.js	GET	200	h2	script	(index)	73.0 kB	71 ms
apstag.js	GET	200	h2	script	(index)	36.7 kB	69 ms
ld.js	GET	200	h2	script	(index)	13.4 kB	170 ms
fbevents.js	GET	200	h3	script	(index):113	26.0 kB	35 ms
40150-b79a7.css	GET	200	h2	text/css	(index)	2.1 kB	70 ms
b94b1-5a4e6.css	GET	200	h2	text/css	(index)	1.1 kB	68 ms
skype-1.jpeg	GET	200	h2	webp	(index)	8.2 kB	33 ms
logo	GET	200	h2	webp	(index)	3.0 kB	29 ms
feature	GET	200	h2	webp	(index)	1.0 kB	33 ms

TU CAM

Podemos ver las request desde el navegador



The screenshot displays the 'Headers' tab in a web browser's developer tools. The 'General' section shows the following details:

- Request URL:** https://skype.softonic.com/
- Request Method:** GET
- Status Code:** 200
- Remote Address:** 35.227.233.104:443
- Referrer Policy:** strict-origin-when-cross-origin

The 'Response Headers' section lists the following headers:

- alt-svc:** clear
- cache-control:** no-cache
- content-encoding:** br
- content-language:** es-ES
- content-security-policy:** upgrade-insecure-requests
- content-type:** text/html; charset=utf-8
- date:** Fri, 10 Sep 2021 09:18:29 GMT
- permissions-policy:** accelerometer=(), autoplay=(), camera=(), encrypted-media=(), fullscreen=(), geolocation=(), microphone=(), midi=(), payment=(), picture-in-picture=(), publickey-credentials-get=(), screen=()
- referrer-policy:** strict-origin-when-cross-origin
- server:** istio-envoy
- strict-transport-security:** max-age=63072000; includeSubDomains; preload
- vary:** user-agent, accept-encoding

TU CAM

PREPARAR LOS DATOS

DIY approach

- Exportación
- Parseo de datos
- Limpieza de datos


```

1 34.216.199.149 - - [10/Sep/2021:14:08:56 +0200] "GET / HTTP/2" 200 16096 "-" "Mozilla/5.0 (Mac
2 34.216.199.149 - - [10/Sep/2021:14:08:57 +0200] "GET / HTTP/2" 200 16096 "-" "Mozilla/5.0 (Mac
3 54.36.148.207 - - [10/Sep/2021:14:09:17 +0200] "GET /cloaking/ HTTP/2" 200 21779 "-" "Mozilla/
4 37.59.226.80 - - [10/Sep/2021:14:14:45 +0200] "POST /wp-cron.php?doing_wp_cron=1631276084.9920
5 66.249.75.152 - - [10/Sep/2021:14:14:44 +0200] "GET /contenido-latent-semantic-index/amp/ HTTP
6 37.0.8.34 - - [10/Sep/2021:14:14:54 +0200] "GET /.env HTTP/2" 503 1269 "-" "Mozilla/5.0 (Macin
7 37.0.8.34 - - [10/Sep/2021:14:14:56 +0200] "GET /wp-content/ HTTP/2" 200 0 "-" "Mozilla/5.0 (M
8 66.249.75.152 - - [10/Sep/2021:14:27:12 +0200] "GET /contenido-latent-semantic-index/ HTTP/2"
9 66.249.75.154 - - [10/Sep/2021:14:27:35 +0200] "GET /wp-includes/js/jquery/ui/effect-highlight
10 66.249.75.154 - - [10/Sep/2021:14:27:35 +0200] "GET /wp-content/plugins/js_composer/assets/css
11 185.191.171.26 - - [10/Sep/2021:14:28:33 +0200] "GET /robots.txt HTTP/2" 200 70 "-" "Mozilla/5
12 185.191.171.11 - - [10/Sep/2021:14:28:34 +0200] "GET /page/2/ HTTP/2" 200 15404 "-" "Mozilla/5
13 77.75.77.36 - - [10/Sep/2021:14:28:59 +0200] "GET /robots.txt HTTP/2" 200 70 "-" "Mozilla/5.0
14 2a02:598:bbbb:2::8049 - - [10/Sep/2021:14:29:01 +0200] "GET /link-building-alex-navarro/ HTTP/
15 66.249.75.156 - - [10/Sep/2021:14:29:19 +0200] "GET /analisis-pagina-web-seo-on-page/ HTTP/2"
16 37.59.226.80 - - [10/Sep/2021:14:31:34 +0200] "POST /wp-cron.php?doing_wp_cron=1631277094.7564
17 2001:41d0:a:7ba0:: - - [10/Sep/2021:14:31:34 +0200] "GET /feed/ HTTP/2" 200 3413 "-" "-"
18 66.249.93.147 - - [10/Sep/2021:14:36:13 +0200] "GET / HTTP/2" 200 16096 "-" "Mozilla/5.0 (X11;
19 66.249.75.156 - - [10/Sep/2021:14:40:38 +0200]
20 88.3.232.131 - - [10/Sep/2021:14:42:04 +0200]

```

	A	B	C	D	E	F	G	H	I	J	K
1	34.216.199.149	-	-	[10/Sep/2021:14:08:56 +0200]		GET / HTTP/2	200	16096	-	Mozilla/5.0 (Macintosh; Intel Mac C	
2	34.216.199.149	-	-	[10/Sep/2021:14:08:57 +0200]		GET / HTTP/2	200	16096	-	Mozilla/5.0 (Macintosh; Intel Mac C	
3	54.36.148.207	-	-	[10/Sep/2021:14:09:17 +0200]		GET /cloaking/ HTTP/2	200	21779	-	Mozilla/5.0 (compatible; AhrefsBot	
4	37.59.226.80	-	-	[10/Sep/2021:14:14:45 +0200]		POST /wp-cron.php?doing_wp_cron=1631276084.9920	200	0	https://seohacks	WordPress/5.0.13; https://seohack	
5	66.249.75.152	-	-	[10/Sep/2021:14:14:44 +0200]		GET /contenido-latent-semantic-index/amp/ HTTP/2	200	14847	-	Mozilla/5.0 (Linux; Android 6.0.1; t	
6	37.0.8.34	-	-	[10/Sep/2021:14:14:54 +0200]		GET /.env HTTP/2	503	1269	-	Mozilla/5.0 (Macintosh; Intel Mac C	
7	37.0.8.34	-	-	[10/Sep/2021:14:14:56 +0200]		GET /wp-content/ HTTP/2	200	0	-	Mozilla/5.0 (Macintosh; Intel Mac C	
8	66.249.75.152	-	-	[10/Sep/2021:14:27:12 +0200]		GET /contenido-latent-semantic-index/ HTTP/2	200	21791	-	Mozilla/5.0 (compatible; Googlebo	
9	66.249.75.154	-	-	[10/Sep/2021:14:27:35 +0200]		GET /wp-includes/js/jquery/ui/effect-highlight/ HTTP/2	200	457	https://seohacks	Mozilla/5.0 AppleWebKit/537.36 (P	
10	66.249.75.154	-	-	[10/Sep/2021:14:27:35 +0200]		GET /wp-content/plugins/js_composer/assets/css/ HTTP/2	200	83964	https://seohacks	Mozilla/5.0 AppleWebKit/537.36 (P	
11	185.191.171.26	-	-	[10/Sep/2021:14:28:33 +0200]		GET /robots.txt HTTP/2	200	70	-	Mozilla/5.0 (compatible; SemrushE	
12	185.191.171.11	-	-	[10/Sep/2021:14:28:34 +0200]		GET /page/2/ HTTP/2	200	15404	-	Mozilla/5.0 (compatible; SemrushE	
13	77.75.77.36	-	-	[10/Sep/2021:14:28:59 +0200]		GET /robots.txt HTTP/2	200	70	-	Mozilla/5.0 (compatible; SeznamB	
14	2a02:598:bbbb:2::8049	-	-	[10/Sep/2021:14:29:01 +0200]		GET /link-building-alex-navarro/ HTTP/2	200	28594	-	Mozilla/5.0 (compatible; SeznamB	
15	66.249.75.156	-	-	[10/Sep/2021:14:29:19 +0200]		GET /analisis-pagina-web-seo-on-page/ HTTP/2	200	20333	-	Mozilla/5.0 (Linux; Android 6.0.1; t	
16	37.59.226.80	-	-	[10/Sep/2021:14:31:34 +0200]		POST /wp-cron.php?doing_wp_cron=1631277094.7564	200	0	https://seohacks	WordPress/5.0.13; https://seohack	
17	2001:41d0:a:7ba0::	-	-	[10/Sep/2021:14:31:34 +0200]		GET /feed/ HTTP/2	200	3413	-	-	
18	66.249.93.147	-	-	[10/Sep/2021:14:36:13 +0200]		GET / HTTP/2	200	16096	-	Mozilla/5.0 (X11; Linux x86_64) Aq	
19	66.249.75.156	-	-	[10/Sep/2021:14:40:38 +0200]		GET /guia-seo/ HTTP/2	200	10774	-	Mozilla/5.0 (compatible; Googlebo	
20	88.3.232.131	-	-	[10/Sep/2021:14:42:04 +0200]		GET /robots.txt HTTP/2	200	70	-	Screaming Frog SEO Spider/15.2	

Exportación



La exportación dependerá del servidor o de tu proveedor de hosting.

En proyectos propios podrás acceder directamente a ellos pero con un cliente siempre tendrás que hablar con IT.

TU CAM

Parseo

El parseo de datos consiste en transformar una cadena de texto (o string) en diferentes tipos de datos una vez transformado

- A mano
- Con scripts
 - JS / Python
 - Bash

TU CAM

A mano

1. Descomprimos los datos y los exportamos en un excel/sheets
2. El patrón de separación será el espacio
3. Realizar separaciones a mano del método, URL y protocolo
4. Limpiar corchetes de fecha y cambio horario
5. Separar fecha y hora
6. Aplicar diferencia horaria
7. Añadir encabezados
8. Listo

TU CAM

A mano

A tener en cuenta:

Si los archivos de logs son muy grandes, hay que dividirlos en otros archivos más pequeños (chunks) o limpiar datos previo al parseo

- Generación de chunks:

- `split [archivo] (1000 líneas por defecto)`

- Filtrar por un patrón:

- `grep -h "Googlebot" [archivo] > [archivo-final]`

- Juntar varios días y filtrar por un patrón

- `cat *.*[extensión] | grep -h "Googlebot" > [archivo-final]`

- Juntar varios días:

- `cat [archivo1] [archivo2] [archivo3] > [archivo-final]`

TU CAM

Resultado final

	A	B	C	D	E	F	G	H	I	J	K	
1	IP	Identity	User	Date	Time	Timezone	Final Date	Method	URL	Protocol	Status Code	
2	34.216.199.149	-	-	10/Sep/2021	14:08:56	02:00:00	16:08:56	GET	/	HTTP/2	200	
3	34.216.199.149	-	-	10/Sep/2021	14:08:57	02:00:00	16:08:57	GET	/	HTTP/2	200	
4	54.36.148.207	-	-	10/Sep/2021	14:09:17	02:00:00	16:09:17	GET	/cloaking/	HTTP/2	200	
5	37.59.226.80	-	-	10/Sep/2021	14:14:45	02:00:00	16:14:45	POST	/wp-cron.php?dc	HTTP/1.1	200	
6	66.249.75.152	-	-	10/Sep/2021	14:14:44	02:00:00	16:14:44	GET	/contenido-latent	HTTP/2	200	
7	37.0.8.34	-	-	10/Sep/2021	14:14:54	02:00:00	16:14:54	GET	/env	HTTP/2	503	
8	37.0.8.34	-	-	10/Sep/2021	14:14:56	02:00:00	16:14:56	GET	/wp-content/	HTTP/2	200	
9	66.249.75.152	-	-	10/Sep/2021	14:27:12	02:00:00	16:27:12	GET	/contenido-latent	HTTP/2	200	
10	66.249.75.154	-	-	10/Sep/2021	14:27:35	02:00:00	16:27:35	GET	/wp-includes/js/jc	HTTP/2	200	
11	66.249.75.154	-	-	10/Sep/2021	14:27:35	02:00:00	16:27:35	GET	/wp-content/plugin	HTTP/2	200	
12	185.191.171.26	-	-	10/Sep/2021	14:28:33	02:00:00	16:28:33	GET	/robots.txt	HTTP/2	200	
13	185.191.171.11	-	-	10/Sep/2021	14:28:34	02:00:00	16:28:34	GET	/page/2/	HTTP/2	200	
14	77.75.77.36	-	-	10/Sep/2021	14:28:59	02:00:00	16:28:59	GET	/robots.txt	HTTP/2	200	
15	2a02:598:bbb2	-	-	10/Sep/2021	14:29:01	02:00:00	16:29:01	GET	/link-building-ale	HTTP/2	200	
16	66.249.75.156	-	-	10/Sep/2021	14:29:19	02:00:00	16:29:19	GET	/analisis-pagina-	HTTP/2	200	
17	37.59.226.80	-	-	10/Sep/2021	14:31:34	02:00:00	16:31:34	POST	/wp-cron.php?dc	HTTP/1.1	200	
18	2001:41d0:a:7be	-	-	10/Sep/2021	14:31:34	02:00:00	16:31:34	GET	/feed/	HTTP/2	200	
19	66.249.93.147	-	-	10/Sep/2021	14:36:13	02:00:00	16:36:13	GET	/	HTTP/2	200	
20	66.249.75.156	-	-	10/Sep/2021	14:40:38	02:00:00	16:40:38	GET	/guia-seo/tf-idf-te	HTTP/2	200	
21	88.3.232.131	-	-	10/Sep/2021	14:42:04	02:00:00	16:42:04	GET	/robots.txt	HTTP/2	200	
22	88.3.232.131	-	-	10/Sep/2021	14:42:05	02:00:00	16:42:05	GET	/crawl-budget-op	HTTP/2	200	
23	66.249.75.154	-	-	10/Sep/2021	14:42:44	02:00:00	16:42:44	GET	/link-building-ale	HTTP/2	200	
24	2a01:4f8:c010:b	-	-	10/Sep/2021	14:51:04	02:00:00	16:51:04	GET	/wp-content/plugin	HTTP/2	200	
25	212.102.33.211	-	-	10/Sep/2021	14:55:07	02:00:00	16:55:07	GET	/cloaking/	HTTP/2	200	
26	212.102.33.211	-	-	10/Sep/2021	14:55:10	02:00:00	16:55:10	POST	/wp-comments-p	HTTP/2	302	
27	37.59.226.80	-	-	10/Sep/2021	15:02:33	02:00:00	17:02:33	POST	/wp-cron.php?dc	HTTP/1.1	200	
28	8.29.198.27	-	-	10/Sep/2021	15:02:33	02:00:00	17:02:33	GET	/feed/	HTTP/2	200	
29	54.36.148.35	-	-	10/Sep/2021	15:10:43	02:00:00	17:10:43	GET	/creando-blog-se	HTTP/2	200	
30	37.59.226.80	-	-	10/Sep/2021	15:10:59	02:00:00	17:10:59	POST	/wp-cron.php?dc	HTTP/1.1	200	
31	66.249.75.132	-	-	10/Sep/2021	15:10:59	02:00:00	17:10:59	GET	/blog/	HTTP/2	200	
32	66.249.75.132	-	-	10/Sep/2021	15:14:36	02:00:00	17:14:36	GET	/robots.txt	HTTP/2	200	
33	66.249.75.135	-	-	10/Sep/2021	15:14:37	02:00:00	17:14:37	GET	/imagenes-origin	HTTP/2	200	
34	66.249.75.135	-	-	10/Sep/2021	15:14:50	02:00:00	17:14:50	GET	/wp-content/plugin	HTTP/2	200	
35	77.75.79.17	-	-	10/Sep/2021	15:15:09	02:00:00	17:15:09	GET	/robots.txt	HTTP/2	200	

TU CAM

Con Scripts

En vez de realizar todo ese proceso a mano (que es bastante tedioso) podemos usar scripts que lo hagan por nosotros.

- Importante: Los logs pueden estar formateados distintos. En la documentación se presentan de una manera pero en el ejemplo que os muestro, los logs tienen un formato distinto. Tened eso en cuenta antes de usar ciertos scripts o puede que no funcionen.

TU CAM

Con Scripts

Parse from string using custom log format

The simplest (if not all that useful) use case is

```
var Alpine = require('alpine');  
var alpine = new Alpine("%h %s %B");  
var data = alpine.parseLine("www.brain-salad.com 403 4321");  
console.log(data);
```

which produces

```
{  
  originalLine: 'www.brain-salad.com 403 4321',  
  remoteHost: 'www.brain-salad.com',  
  status: '403',  
  size: '4321'  
}
```

<https://github.com/blasen/node-alpine>

TU CAM

Con Scripts

99 lines (91 sloc) | 3.21 KB

```
1 import gzip
2 import re
3 import pandas as pd
4 import socket
5 from IPython.core.display import clear_output
6
7 def check_googlebot(ips):
8     verified = []
9     for ip in range(len(ips)):
10         try:
11             verify = socket.gethostbyaddr(ips[ip])
12             gf = verify[0].find(".")
13             gfi = verify[0].find(".", gf+1)
14             host = verify[0][gf+1:gfi]
15             if host == "google" or host == "googlebot":
16                 verified.append("verified")
17             else:
18                 verified.append("fake")
19         except:
20             verified.append("fake")
21
22     print("Verifying " + str(ip) + " of " + str(len(ips)-1))
23     clear_output(wait = True)
24
25     return verified
26
27 def read_logs(file, type_file):
28
29     ips,date,hour,diff,method,url,status_code,download,referrer,user_agent=[], [], [], [], [], [], [], [], []
30     if type_file == "gzip":
31         with gzip.open(file, 'rb') as f:
32             log_decompressed = f.read()
33     elif type_file == "log":
34         f = open(file, 'rb')
35         log_decompressed = f.read()
```

https://github.com/NachoSEO/read_logs/blob/master/read_logs.py

TU CAM

Con Scripts

Con UNIX podemos aplicar ciertos comandos que no solo nos pueden ayudar a parsear los datos, sino también a limpiarlos e incluso extraer información.

```
nacho.mascort@ST-A210-95QLVDL ➤ ~/downloads ➤ awk '{print $9}' logs-combined | sort | uniq -c | sort -rn  
208 200  
6 304  
3 503  
3 412  
2 404  
2 301  
1 500  
1 401  
1 302
```

TU CAM

Limpiar datos

En la fase final de proceso limpiaremos los datos que no vayamos a usar

- Filtrar solo por ciertos bots
 - Googlebot, Bingbot, Ahrefsbot...
- Eliminar los fake bots
 - nslookup
- Filtrar por ciertas secciones de la web o ciertas fechas
- Eliminar ciertos tipos de archivos
- ...


TU CAM



Herramientas de terceros

- Screaming frog log file analyzer
- ELK
 - Kibana
 - Oncrawl
 - ...

Screaming Frog Log Analyzer



TU CAM

Screaming Frog Log Analyzer

General

User Agents

Include

Remove Parameters

☒ Filter User Agents (Improves Performance)

Available

Googlebot Mobile

Googlebot Images

Googlebot News

DuckDuckGo

Yahoo!

AppleBot

Seznam

Sogou

Search...

Configure User Agents

Selected

Googlebot

Googlebot Smartphone

Bingbot

Yandex

Baidu

Screaming Frog SEO Spider

Search...


☐ Verify Bots When Importing Logs (Slows down Import)

<https://www.screamingfrog.co.uk/log-file-analyser/>

Incluye versión gratuita con datos de demostración


TU CAM

Screaming Frog Log Analyzer




TU CAM

ELK Kibana



TU CAM



ELK Oncrawl


Analizador de logs en local

1. Instalar [docker](#)
2. Instalar [ELK de Oncrawl](#)
3. Configurar la imagen
4. Ejecutar docker-compose
5. Importar logs
6. Analizar

TU CAM

ANÁLISIS DE DATOS

Softonic Googlebot pagetypes



Añadiendo una capa extra

- Page types
- Compliant vs non-compliant
- Por proyectos / instancias
- Por cluster donde se aloja cada server
- Otros meta datos

TU CAM


Análisis básicos

- ¿Qué User-agent navega más por mi web?
- ¿Ya estoy en el mobile first?
- ¿Qué páginas visita más frecuentemente? ¿De qué tipo?
- Detectar dónde se está desperdiciando Crawl budget
- Detectar errores y otros patrones
- Monitorización de códigos de estado
- Crawling de páginas indexadas vs no indexadas

TU CAM

¿Qué User-agent navega más por mi web?

Count of User-agent



TU CAM

¿Qué User-agent navega más por mi web?


- Detectar qué bots realizan más hits
- Ver si hay algún CRON que consume demasiados recursos para limitarlo o eliminarlo
- Bloquear aquellos que consumen demasiados recursos o que no son “fraudulentos”
- Podemos usar servicios (Cloudflare, Istio, Fastly) que limiten los hits de ciertos bots para mantener la estructura estable
 - El código de estado 429 es el idóneo para estos casos

TU CAM

¿Ya estoy en el mobile first?

fx

```
=IF(REGEXMATCH(N2,"Android"),"yes","no")
```



*Verifica la información con más días de datos y con Search Console


TU CAM

¿Ya estoy en el mobile first?

- En función del número de hits por Googlebot y de Search Console podremos validar dicha afirmación
- También nos puede ayudar a definir una configuración mobile más adecuada para nuestro site
 - Responsive
 - Dynamic Serving
 - Urls distintas para cada versión (m.dominio.com)

TU CAM


¿Qué páginas visita más frecuentemente? ¿De qué tipo?



TU CAM

¿Qué páginas visita más frecuentemente? ¿De qué tipo?

Count of Type



TU CAM

¿Qué páginas visita más frecuentemente? ¿De qué tipo?

- Detectar las páginas más importantes para negocio y ver si también lo son para Google
 - Si no, podemos modificar el enlazado interno o la jerarquía de la web para dotar de más importancia a esas páginas (los hits deberían ser una pista de esto)
- Detectar dónde se está desperdiciando más crawling y modificar la estructura del site para reconducir
 - Dependiendo lo grande que sea un site, esto puede no tener sentido (>100k)

TU CAM

Monitorización de status code

Status Code	Total Log Requests	Percentage of Total Log Requests	Average Log Requests per URL
200	476,030	97.14%	1.7
301	5,096	2.27%	0.6
500	903	0.30%	0.2
404	790	0.25%	0.01
302	45	0.04%	1.2

Monitorización de código de estado

- Arreglar los código de estado 500 y 4xx (en la medida que se pueda)
 - Los 4xx son un estado natural del site, tener no es perjudicial pero podemos redirigirlas para reconducir esas señales previas
- Los 3xx pueden indicar que hay enlaces internos deprecados y necesitaremos reemplazar para que apunten directamente a los 200
 - Igual que con los 4xx, los 3xx son un estado natural y es normal mantener una porcentaje de estos en el site

TU CAM

Crawling de indexadas vs no indexadas

Indexable	Total Log Requests	Percentage of Total Log Requests	Average Log Requests per URL
TRUE	474,014	97.30%	5
FALSE	7,311	2.70%	0.03

Crawling de indexadas vs no indexadas

- ¿Existe alguna URL no indexada con muchas peticiones?
 - Podemos buscar motivos (enlaces externos, internos, algún cambio reciente...) para tomar la decisión de si reindexarla de nuevo o no
- ¿Se está focalizando Google en partes del site que no queremos y un noindex no es suficiente?
 - Podemos eliminar dichas páginas o hacerlas más profundas

TU CAM

Otros análisis básicos

- Detectar dónde se está desperdiciando Crawl budget
- Detectar errores
- Ampliar los datos con más días para ver cómo evolucionan ciertas partes de la web

Path	Num Events ▼	Average Bytes	Average Response Time (ms)	All Bots
http/	361	1648956	897	361
▼ example.com/	361	1648956	897	361
js/	23	2885	786	23
download/	22	11048346	764	22
blog/	11	9474	720	11

TU CAM

Contar el número de hits de una URL con una QUERY dinámica

```
=iferror(  
  index(  
    QUERY(  
      'datos limpios - Googlebot only'!1:800,  
      "SELECT count(I) WHERE I = '"&A2&"' ", 0),  
    2,  
    0),  
0)
```

TU CAM

Análisis avanzados

- ¿Google esta renderizando mis URLs?
- Relación entre crawling y profundidad
- Detectar fake Googlebots
- Relación entre autoridad (PR) y crawling
- ...

TU CAM

¿Google esta renderizando mis URLs?

URL	Referrer
/wp-includes/js/jquery/ui/effect-highlight.min.js?ver=1.11.4	https://seohacks.es/contenido-latent-semantic-index/
/wp-content/plugins/js_composer/assets/css/js_composer.css?ver=4.7.4	https://seohacks.es/contenido-latent-semantic-index/
/wp-content/plugins/thrive-visual-editor/thrive-dashboard/js/dist/frontend.min.js?ver=2.2.12	https://seohacks.es/imagenes-originales/
/wp-content/plugins/fancier-author-box/css/ts-fab.min.css?ver=1.4	https://seohacks.es/page/2/
/wp-content/plugins/thrive-visual-editor/editor/css/thrive_flat.css?ver=2.5.0	https://seohacks.es/nacho-mascort/

TU CAM

¿Google esta renderizando mis URLs?

- Sobre todo para los sites basados en JS en cliente
 - React
 - Vue
 - Angular
 - ...
- Detectar si hay recursos que no cargan o se consumen demasiado (y malgastan crawl)
 - Modificar los chunks de ficheros estáticos
 - Validar nuestra configuración de renderización
 - SSR
 - CSR

TU CAM

Detectar fake Googlebots

- Script custom + merge de datos
- Usar herramientas de terceros (Screaming Frog)

```
verifyGooglebots() {  
  cat "$1" \  
  | grep "Mozilla/5.0 (compatible; Googlebot/2.1; +http://www.google.com/bot.html)" \  
  | awk '{print $1}' | sort | uniq -c | sort -nr | awk '{print $2}' > ./info/ips.txt  
  
  while read li; do nslookup $li | grep name | grep "googlebot.com.$" \  
  | sed -e "s/^/$li /" | awk '{print $1}' ; done <./info/ips.txt >./info/potentiallygoogle.txt  
  
  wc -l ./info/potentiallygoogle.txt  
  
  grep -f ./info/potentiallygoogle.txt "$1" > ./output/googlebotacces.log  
}
```

TU CAM

Detector fake Googlebots

Input

Let's imagine a Log file with the following content:

```
66.249.75.152 - - [10/Sep/2021:14:14:44 +0200] "GET /contenido-latent-semantic-index/amp/ HTTP/2" 200 0 "-" "Mozilla/5.0 (Macintosh; Intel Mac OS X 10_15_7; rv:68.0) Gecko/20100101 Firefox/68.0"
142.170.179.34 - - [10/Sep/2021:14:14:54 +0200] "GET /.env HTTP/2" 503 1269 "-" "Mozilla/5.0 (Macintosh; Intel Mac OS X 10_15_7; rv:68.0) Gecko/20100101 Firefox/68.0"
142.170.179.34 - - [10/Sep/2021:14:14:56 +0200] "GET /wp-content/ HTTP/2" 200 0 "-" "Mozilla/5.0 (Macintosh; Intel Mac OS X 10_15_7; rv:68.0) Gecko/20100101 Firefox/68.0"
```

Output

If we run the function we get the following output:

```
66.249.75.152 - - [10/Sep/2021:14:14:44 +0200] "GET /contenido-latent-semantic-index/amp/ HTTP/2" 200 0 "-" "Mozilla/5.0 (Macintosh; Intel Mac OS X 10_15_7; rv:68.0) Gecko/20100101 Firefox/68.0"
```

<https://github.com/NachoSEO/verify-googlebots>


TU CAM

Detectar fake Googlebots

- Podemos buscar que fake Googlebots nos están rastreando
 - Posibles competidores monitorizando
 - Posibles scrapers extrayendo contenido
 - Posibles spammers intentando encontrar una vulnerabilidad
- Es importante coordinarse con el equipo técnico para poder bloquear algunos de estos comportamientos
 - Un bot bien configurado puede ser prácticamente imparable
 - Si no hay un patrón por el que identificarle tipo IP, localización, user-agent o similar

TU CAM

Relación entre crawling y profundidad



TU CAM

Relación entre autoridad (PR) y crawling

1. Crawl el site para extraer la relación de interlinking
2. Usar uno de los algoritmos del PR para extraer autoridad de cada página (sin tener en cuenta enlaces externos)
 - a. Link Scoring de Screaming Frog nos puede servir
3. Añadir esos datos a los logs

TU CAM

Relación entre autoridad (PR*) y crawling


A	B	C
Address	Hits	PR
/	5	99
/nacho-mascort/	4	98
/contenido-latent-semantic-index/	4	95
/blog/	2	98
/imagenes-originales/	2	93
/ddos/	1	95
/guia-quality-raters-google/	1	95
/cloaking/	1	94
/page/2/	1	5

TU CAM

Relación entre autoridad (PR) y crawling

- Detectar oportunidades de cambio jerarquía
 - Páginas importantes para negocio en niveles muy profundo
- Las paginaciones pueden ser uno de los principales problemas de profundidad
 - Limitar las paginaciones a un número finito y trabajar el interlinking entre “páginas de producto”. Interlinking algorítmico suele funcionar bastante bien
- Detectar si algún nivel profundo recibe más hits “de lo normal”
 - Tal vez hay que modificar las categorizaciones de un site
 - Controlar el enlazado externo

Crawl stats de Search Console



TU CAM

Crawl stats de Search Console



Host had no problems in the last 90 days


Google was generally able to crawl your site. [Learn more](#)

Details

✓ robots.txt fetch ?	Acceptable fail rate	▼
✓ DNS resolution ?	Acceptable fail rate	▼
✓ Server connectivity ?	Acceptable fail rate	▼

TU CAM

Crawl stats de Search Console



Examples

Time ↓	URL	Response
16/09/2021, 06:56	https://seohacks.es/contenido-latent-semantic-index/	OK (200)
15/09/2021, 16:02	https://seohacks.es/ddos	Moved permanently (301)
15/09/2021, 16:02	https://seohacks.es/ddos/	OK (200)
15/09/2021, 10:21	https://seohacks.es/guia-seo/foro-seo-2/	OK (200)
15/09/2021, 09:36	https://seohacks.es/evolucion-blog/	OK (200)
14/09/2021, 20:41	https://seohacks.es/blog/	OK (200)

TU CAM

Referencias

- <https://seohacks.es/crawl-budget-optimizar-http-304/>
- <https://www.w3.org/Daemon/User/Config/Logging.html#common-logfile-format>
- <http://httpd.apache.org/docs/2.4/logs.html>
- <https://docs.nginx.com/nginx/admin-guide/monitoring/logging/>
- <https://docs.microsoft.com/en-us/iis/manage/provisioning-and-managing-iis/configure-logging-in-iis>
- <https://moz.com/blog/seo-finds-in-your-server-log>
- <https://github.com/cogniteev/oncrawl-elk/>
- <https://johnmu.com/fake-googlebots/>
- <https://dev.to/flippedcoding/the-importance-of-log-files-37d6>
- <https://www.howtogeek.com/359463/what-is-a-log-file>
- <https://www.semrush.com/kb/880-access-log>
- <https://developer.mozilla.org/en-US/docs/Web/HTTP/Methods>
- <https://developer.mozilla.org/en-US/docs/Web/HTTP/Status>
- <https://www.seroundtable.com/google-crawling-half-of-the-urls-over-http-2-31444.html>
- <https://www.searchenginejournal.com/command-line-seo-guide/418782/#close>
- <https://github.com/blarsen/node-alpine>
- https://github.com/NachoSEO/read_logs/blob/master/read_logs.py
- <https://mauricius.dev/parse-log-files-with-awk/>
- <https://www.elastic.co/es/kibana/>
- <https://www.screamingfrog.co.uk/log-file-analyser/>
- <https://www.oncrawl.com/technical-seo/how-to-do-log-file-analysis-for-free/>
- <https://www.mecagoenlos.com/Posicionamiento/ver-las-urls-rendेरizadas.php#gref>
- <https://www.mecagoenlos.com/Posicionamiento/la-segunda-ola-de.php>
- <https://towardsdatascience.com/pagerank-3c568a7d2332>
- <https://searchwilderness.com/pagerank-screamingfrog-r/#gref>
- <https://searchengineland.com/improve-internal-linking-calculate-internal-pagerank-r-246883>
- <https://www.searchenginejournal.com/seo-log-file-analysis-guide/419660>

TU CAM

¡MUCHAS GRACIAS!

TU CAM